

Pesquisa Operacional

Igor M. Coelho

6 de Julho de 2020

- 1 Método Simplex
- 2 História do Simplex
- 3 Fundamentos do Simplex
- 4 Detalhamento do Simplex
- 5 Exemplo com Python
- 6 Tableau Simplex

Section 1

Método Simplex

Sobre esse material

Esses slides foram possíveis devido a contribuições de diversas pessoas/materiais, em especial:

- Notas do prof. Marcone Jamilson Freitas Souza
- Livro Nelson Maculan e Marcia Fampa
- Livro-texto do curso
- [2] Tutorial ilectures
(<https://igormcoelho.github.io/ilectures-pandoc/>)
- Minha esposa Cristiane Tavares pelas valiosas dicas na elaboração desse material

Fundamentos Necessários

Caso não se sintam confiantes nos tópicos abaixo, façam uma revisão antes de aprofundar neste material:

- Álgebra Linear e Geometria Analítica
 - Equação da Reta
 - Operações Vetoriais
 - Operações com Matrizes
- Métodos Numéricos
 - Método da Eliminação de Gauss
- Cálculo
 - Gradientes e Otimização

Section 2

História do Simplex

Breve história

De acordo com Maculan&Fampa (2006)¹, as primeiras ideias de como otimizar um sistema de desigualdades lineares foi explorado por Fourier² em 1880, porém somente George Dantzig³ em 1947 que de fato propôs o método de resolução *simplex*.

O simplex é um algoritmo reconhecidamente bem-sucedido, tendo sido implementado em diversos *solvers* de computador altamente eficientes, como CPLEX, Gurobi, CBC (*open-source*), etc.

¹N. Maculan e M. Fampa. *Otimização Linear*. Editora UnB, 2006.

²Fourier, J.B.J. *Oeuvres*. "Second Extrait", G. Darboux, Gauthiers-Villars, p. 325-328, 1880.

³Dantzig, George B. Maximization of a linear function of variables subject to linear inequalities. *Activity Analysis of Production and Allocation*. In: KOOPMANS, C. (Ed.). New York: Wiley, p. 359-373, 1951.

Aplicações no planejamento da produção e outros métodos

Em 1939, L. Kantorovich⁴ modelou e resolveu matematicamente problemas de planejamento da produção na União Soviética, ganhando o prêmio Nobel de Economia em 1975.

Outros métodos para resolução: Métodos Elipsoidais de L. Khachian⁵ em 1978; Métodos de Pontos Interiores de N. Karmarkar⁶ em 1984; embora elegantes (com garantia de tempo polinomial), são tipicamente menos eficientes na prática que o simplex.

⁴Kantorovich, L. *Métodos Matemáticos na Organização e no Planejamento da Produção* (em russo). Leningrado: Editora da Univ. Estatal de Leningrado, 1939 (tradução inglesa: *Management Science*, v.6, p. 366-422, 1960).

⁵Khachian, L. A polynomial algorithm for linear programming. *Doklady Akademii Nauk SSSR*, v.244, p.191-194 (em russo. Tradução em inglês: *Soviet Mathematics Doklady*, v.20, p.191-194, 1979.).

⁶Karmarkar, N. A new polynomial algorithm for linear programming. *Combinatorica*, v.4, p.373-395, 1984.

Section 3

Fundamentos do Simplex

Um Problema de Programação Linear

Considere o seguinte problema de programação linear:

$$\text{maximizar } f(x) = \sum_{j=1}^p c_j x_j$$

Sujeito a:

$$\sum_{j=1}^p a_{ij} x_j \leq b_i, \quad i = 1, 2, \dots, q$$

$$x_j \geq 0, \quad j = 1, 2, \dots, p$$

onde: c_j , a_{ij} e b_i são dados (números reais) e x_j representa as variáveis de decisão (não-negativas). Consideramos, neste caso, uma função objetivo $f(x)$ de maximização, e restrições do tipo \leq .

Variáveis de Folga

Restrições do tipo \leq (ou \geq) podem ser facilmente transformadas em igualdades, com a introdução de novas variáveis (não-negativas) de folga/falta (do inglês, *slack/surplus*):

$$\sum_{j=1}^p a_{ij}x_j \leq b_i \iff \begin{cases} \sum_{j=1}^p a_{ij}x_j + x_{p+1} = b_i, \\ x_{p+1} \geq 0 \end{cases}$$

$$\sum_{j=1}^p a_{ij}x_j \geq b_i \iff \begin{cases} \sum_{j=1}^p a_{ij}x_j - x_{p+1} = b_i, \\ x_{p+1} \geq 0 \end{cases}$$

Variáveis de Folga (exemplo)

Um exemplo de transformação de \leq em igualdade (introduzindo variável de folga x_3):

$$2x_1 + 3x_2 \leq 5 \Rightarrow 2x_1 + 3x_2 + \underbrace{x_3}_{x_3 \geq 0} = 5$$

O mesmo para restrições \geq (introduzindo variável x_4):

$$x_1 + 6x_2 \geq 7 \Rightarrow x_1 + 6x_2 - \underbrace{x_4}_{x_4 \geq 0} = 7$$

Outras conversões à forma padrão

Demais técnicas de conversão de variáveis/restrições:

- Existe $b_i < 0$:
 - **Solução:** multiplique a restrição i por -1
- Existem variáveis não positivas (seja $x_k \leq 0$):
 - **Solução:** Substituir por variável $x'_k \geq 0$ tal que $x'_k = -x_k$
- Existem variáveis livres (seja $x_k \in \mathbb{R}$):
 - **Solução:** substituir x_k por $x'_k - x''_k$, tal que $x'_k \geq 0$ e $x''_k \geq 0$
- Um problema de minimização pode ser convertido em maximização (vice-versa):

$$\text{maximizar } f(x) = -\text{minimizar } \{-f(x)\}$$

Problema de Programação Linear Padrão

Sempre poderemos escrever um **problema de programação linear na forma padrão (PPL)**:

$$(PPL) : \text{maximizar } f(x) = \sum_{j=1}^n c_j x_j$$

$$\sum_{j=1}^n a_{ij} x_j = b_i, \quad i = 1, 2, \dots, m$$

$$x_j \geq 0, \quad j = 1, 2, \dots, n$$

tendo assim, n variáveis e m restrições.

Problema de Programação Linear Padrão (vetores)

De forma equivalente, podemos representar o PPL na forma vetorial:

$$(PPL) : \text{maximizar } z = cx$$

$$Ax = b$$

$$x \geq 0$$

onde $c = (c_1 \ c_2 \ \dots \ c_n)$, $x^T = (x_1 \ x_2 \ \dots \ x_n)$, $b^T = (b_1 \ b_2 \ \dots \ b_m)$, $A = (a_1 \ a_2 \ \dots \ a_n)$ e $a_j^T = (a_{1j} \ a_{2j} \ \dots \ a_{mj})$, isto é, $c^T \in \mathbb{R}^n$, $x \in \mathbb{R}^n$, $b \in \mathbb{R}^m$, $A \in \mathbb{R}^{m \times n}$ e $a_j \in \mathbb{R}^m$.

Definição 2.1 (Maculan&Fampa) Seja

$X = \{x \in \mathbb{R}^n | Ax = b, x \geq 0\}$ a **região viável** do PPL, e $x \in X$ uma **solução viável** do PPL. Se $x^* \in X$ tal que $cx^* \geq cx, \forall x \in X$, x^* é uma **solução ótima**.

Exemplo de PPL

$$\begin{array}{llll}
 \max & x_1 & +2x_2 & \\
 & x_1 & & \leq 2 \\
 & & x_2 & \leq 2 \\
 & x_1 & +x_2 & \leq 3 \\
 & x_1, & x_2 & \geq 0
 \end{array} \Rightarrow$$

$$\begin{array}{llllll}
 \max & x_1 & +2x_2 & +0x_3 & +0x_4 & +0x_5 \\
 & x_1 & & +x_3 & & = 2 \\
 & & x_2 & & +x_4 & = 2 \\
 & x_1 & +x_2 & & & +x_5 = 3 \\
 & x_1, & x_2, & x_3, & x_4, & x_5 \geq 0
 \end{array}$$

$$\underbrace{\begin{bmatrix} 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 \\ 1 & 1 & 0 & 0 & 1 \end{bmatrix}}_{A} \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix}}_x = \underbrace{\begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}}_b$$

Matriz básica e não-básica

A matriz $\mathcal{A}_{m \times n}$ pode ser particionada da seguinte maneira (supondo $\text{posto}(\mathcal{A}) = m$, com m colunas independentes):

$$\mathcal{A} = (\mathcal{B} \mathcal{N})$$

onde $\mathcal{B}_{m \times m}$, chamada de matriz básica, é inversível; e $\mathcal{N}_{m \times (n-m)}$ é chamada de não-básica. Analogamente, particionamos x e c , tal que: $x^T = (x_B^T \ x_N^T)$, $c = (c_B \ c_N)$. Vetores x_B e c_B possuem m componentes associadas à matriz \mathcal{B} . Reescrevemos o PPL:

$$(PPL) : \text{maximizar } z = c_B x_B + c_N x_N$$

$$\mathcal{B} x_B + \mathcal{N} x_N$$

$$x_B \geq 0, x_N \geq 0$$

Solução básica e não-básica

Explicitamos x_B em função de x_N (Eq. 2.10 em Maculan&Fampa):

$$x_B = \mathcal{B}^{-1}b - \mathcal{B}^{-1}\mathcal{N}x_N$$

Faremos $x_N = 0$ e $\bar{x}_B = \mathcal{B}^{-1}b$.

Definição 2.2 (Maculan&Fampa) \bar{x} é uma **solução básica**, se $\bar{x}^T = (\bar{x}_B^T \ 0)$.

Quando $\bar{x}_B \geq 0$, será uma **solução básica viável**.

Sejam I_B o conjunto dos índices das colunas de \mathcal{A} pertencendo à matriz \mathcal{B} , e I_N os demais índices de \mathcal{A} , tal que: $I_B \cap I_N = \emptyset$ e $I_B \cup I_N = \{1, 2, \dots, n\}$.

PPL com matriz básica

$$(PPL) : \text{maximizar } z = c_B \mathcal{B}^{-1} b - (c_B \mathcal{B}^{-1} \mathcal{N} - c_N) x_N$$

Sujeito a:

$$x_B = \mathcal{B}^{-1} b - \mathcal{B}^{-1} \mathcal{N} x_N$$

$$x_B \geq 0, x_N \geq 0$$

PPL com notação aprimorada

De acordo com Maculan&Fampa, definiremos:

- $\lambda = c_B \mathcal{B}^{-1}$, $\lambda^T \in \mathbb{R}^m$
- $\bar{x}_B = \mathcal{B}^{-1}b$, $\bar{x}_B \in \mathbb{R}^m$
- $z_j = \lambda a_j$, ($j \in I_B \cup I_N$), $z_j \in \mathbb{R}$
- $y_j = \mathcal{B}^{-1}a_j$, ($j \in I_B \cup I_N$), $y_j \in \mathbb{R}^m$
- $\bar{z} = c_B \mathcal{B}^{-1}b = \lambda b = c_B \bar{x}_B$.

Então teremos um novo PPL aprimorado:

$$(PPL) : \text{maximizar } z = \bar{z} - \sum_{j \in I_N} (z_j - c_j)x_j$$

sujeito a:

$$x_B = \bar{x}_B - \sum_{j \in I_N} y_j x_j$$

Otimidade no PPL

Proposição 2.1 (de Maculan&Fampa) Se $\bar{x}_B \geq 0$ e $z_j - c_j \geq 0$,
 $\forall j \in I_N$, então o vetor $x^* \in \mathbb{R}^n$, onde $x_{B(i)}^* = \bar{x}_{B(i)}$,
 $i = 1, 2, \dots, m$ e $x_j^* = 0, j \in I_N$, será uma solução
ótima do (PPL).

Focaremos agora na versão do Simplex por tabelas, após apresentar um pseudo-código do algoritmo (com base no livro-texto de Arenales).

Section 4

Detalhamento do Simplex

Simplex para problemas de \leq

O Simplex consiste de duas fases, onde a primeira consiste em encontrar uma base \mathcal{B} .

Para problemas com restrições \leq , as variáveis de folga introduzidas no modelo irão naturalmente formar uma matriz identidade \mathcal{I}_m .

Assim, escolheremos essas variáveis de folga como *variáveis básicas*, atribuindo valor zero a todas as demais *variáveis não-básicas* (originais do modelo). Teremos assim uma base inversível $\mathcal{B} = \mathcal{I}_m$. Neste caso, a primeira fase do Simplex já é naturalmente efetuada.

Pseudo-código do Simplex (Fase II) livro-texto

1 Passo 1: cálculo da solução básica

$$\begin{cases} \bar{x}_B = \mathcal{B}^{-1}b \\ \bar{x}_N = 0 \end{cases}$$

2 Passo 2: cálculo dos custos relativos

1 Vetor multiplicador simplex

- $\lambda^T = c_B^T \mathcal{B}^{-1}$

2 Custos relativos

- $\hat{c}_{N(j)} = c_{N(j)} - \lambda^T a_{N(j)}, j = 1, 2, \dots, n - m$

3 Determinação de variável a entrar na base

- $\hat{c}_{N(k)} = \min\{\hat{c}_{N(j)}, j = 1, \dots, n - m\}$ (a variável $x_{N(k)}$ entra na base)

3 Passo 3: teste de otimalidade (minimização)

- Se $\hat{c}_{N(k)} \geq 0$, então: *pare* (solução atual é ótima!).

Pseudo-código do Simplex (Fase II) livro-texto

- ④ Passo 4: Cálculo da direção Simplex
 - $y = \mathcal{B}^{-1} a_{N(k)}$
- ⑤ Passo 5: Determinação do passo e variável a sair da base
 - Se $y \leq 0$, então: *pare* (não existe solução ótima finita:
 $f(x) \rightarrow -\infty$)
 - Caso contrário, determine a variável a sair da base pela razão mínima:

$$\hat{\varepsilon} = \frac{\hat{x}_{B(\ell)}}{y_\ell} = \min \left\{ \frac{\hat{x}_{B(i)}}{y_i} : y_i > 0, i = 1, \dots, m \right\}$$

(variável $x_{B(\ell)}$ sai da base)

- ⑥ Passo 6: atualização
 - matriz básica: $\mathcal{B} = (a_{B(1)} \dots a_{B(\ell-1)} a_{N(k)} a_{B(\ell+1)} \dots a_{B(m)})$
 - não-básica: $\mathcal{N} = (a_{N(1)} \dots a_{N(k-1)} a_{B(\ell)} a_{N(k+1)} \dots a_{N(n-m)})$
 - incrementa iteração e volte ao Passo 1

Section 5

Exemplo com Python

Exemplo do Simplex

Vide “Exemplo 2.26” do livro-texto de Arenales (página 85).

$$\begin{array}{rcll} \text{minimizar } f(x_0, x_1) = & -x_0 & -2x_1 & \\ & x_0 & +x_1 & \leq 6 \\ & x_0 & -x_1 & \leq 4 \\ & -x_0 & +x_1 & \leq 4 \\ & x_0, & x_1 & \geq 0 \end{array}$$

Solução Básica Ótima: $x_B = (x_0, x_3, x_1)$, tal que $f(x_B) = -11$

Exemplo com Python (dados do problema)

Primeiramente, adicionamos restrições de folga \leq (novas variáveis x_2 , x_3 e x_4), e obtemos uma matriz identidade \mathcal{I}_3 como base \mathcal{B} para o passo 1 do Simplex: $B = (2, 3, 4)$.

Dados do problema:

	x_0	x_1	x_2	x_3	x_4	b
\mathcal{A}	1	1	1	0	0	6
$^{\wedge}$	1	-1	0	1	0	4
$^{\wedge}$	-1	1	0	0	1	4
c	-1	-2	0	0	0	Min f

Exemplo com Python (construindo base)

```
import numpy as np
A=np.array([[1,1,1,0,0],[1,-1,0,1,0],[-1,1,0,0,1]])
b=np.array([6,4,4])
c=np.array([-1, -2, 0, 0, 0])
#
IB=[2,3,4]  # variaveis "de folga" na base
IN=[0,1]    # variaveis "originais" não-básicas
# Construindo a Base a partir das variáveis dadas
Base=np.transpose(np.asarray([A[:,IB[0]], A[:,IB[1]],
                              A[:,IB[2]]]))

#>>> Base
#array([[1, 0, 0],
#       [0, 1, 0],
#       [0, 0, 1]])
```

Exemplo com Python (primeira iteração - passo 1)

Passo 1 - Cálculo da solução básica (resolva $B \cdot x_B = b$) e obtenha:

$$\hat{x}_B = \begin{pmatrix} 6 \\ 4 \\ 4 \end{pmatrix}$$

```
x = np.linalg.inv(Base).dot(b)
```

```
#>>> x
```

```
#array([6., 4., 4.])
```

Exemplo com Python (primeira iteração - passo 2)

Passo 2 - Calcule custos relativos (para N_0 e N_1):

$c_B = (c_{B(0)}, c_{B(1)}, c_{B(2)})$, $B^T \lambda = c_B$, onde $\lambda^T = (0, 0, 0)$.

```
cB = [ c[IB[0]], c[IB[1]], c[IB[2]] ]
```

```
# calcula "lambda" (chamado 'u' aqui)
```

```
u = np.linalg.inv(np.transpose(Base)).dot(cB)
```

```
#>>> u
```

```
#array([0., 0., 0.])
```

- $\hat{c}_0 = c_0 - \lambda^T a_0 = -1$

```
a0 = A[:,0]
```

```
cr0 = c[0] - u.dot(a0)
```

```
#>>> cr0
```

```
#-1.0
```

- $\hat{c}_1 = c_1 - \lambda^T a_1 = -2$

```
a1 = A[:,1]
```

```
cr1 = c[1] - u.dot(a1)
```

```
#>>> cr1
```

```
#-2.0
```

($x_{B(1)} = x_1$ entra na base)

Exemplo com Python (primeira iteração - passos 3-6)

Passo 3 dispensado ($\hat{c}_1 = -2 < 0$), solução não é ótima! Vamos ao passo 4 para cálculo da direção simplex: resolva $\mathcal{B}y = a_1$ e obtenha $y^T = (1 \ -1 \ 1)$.

```
y = np.linalg.inv(Base).dot(a1)
#>>> y
#array([ 1., -1.,  1.])
#>>> x
#array([6., 4., 4.])
#>>> x/y
#array([ 6., -4.,  4.])
```

Escolhemos $\hat{\varepsilon} = \frac{\hat{x}_{B(2)}}{y_2} = 4$, então $x_{B(2)} = x_4$ sai da base:
 $B = (2, 3, 1)$, $N = (0, 4)$, $f(x) = f(\hat{x}) + \hat{c}_{N(k)}\hat{\varepsilon} = 0 - 2 \times 4 = -8$.

Exemplo com Python (segunda iteração - passos 1-6)

Passo 1 - Cálculo da solução básica (resolva $B \cdot x_B = b$) e obtenha:

$$\hat{x}_B = \begin{pmatrix} 2 \\ 8 \\ 4 \end{pmatrix}$$

```
IB=[2,3,1]  # variaveis na base
IN=[0,4]    # variaveis fora da base
# Construindo a Base a partir das variáveis dadas
Base=np.transpose(np.asarray([A[:,IB[0]], A[:,IB[1]],
                              A[:,IB[2]]]))
x = np.linalg.inv(Base).dot(b)
#>>> x
#array([2., 8., 4.] )
```

Avance nos passos 2-6 e obtenha: $B = (0, 3, 2)$, $N = (2, 4)$.

Exemplo com Python (terceira iteração)

Passo 1 - Cálculo da solução básica (resolva $B \cdot x_B = b$) e obtenha:

$$\hat{x}_B = \begin{pmatrix} 1 \\ 8 \\ 5 \end{pmatrix}$$

```
IB=[0,3,1] # variaveis na base
IN=[2,4]   # variaveis fora da base
# Construindo a Base a partir das variáveis dadas
Base=np.transpose(np.asarray([A[:,IB[0]], A[:,IB[1]],
                              A[:,IB[2]]]))
x = np.linalg.inv(Base).dot(b)
#>>> x
#array([1., 8., 5.] )
```

Avance ao passo 2 e descubra que solução é ótima!

Exemplo com Python (solução ótima)

Obtenha valor $f(x) = -11$ na solução ótima $\hat{x}^T = (1, 5, 0, 8, 0)$:

```
IB=[0,3,1]   # variaveis na base
IN=[2,4]     # variaveis fora da base
# Construindo a Base a partir das variáveis dadas
Base=np.transpose(np.asarray([A[:,IB[0]], A[:,IB[1]],
                              A[:,IB[2]]]))
x = np.linalg.inv(Base).dot(b)
#>>> x
#array([1., 8., 5.])
cB = [ c[IB[0]], c[IB[1]], c[IB[2]] ]
#>>> sum(cB*x)
#-11.0
```

Section 6

Tableau Simplex

Simplex por Tabelas

Uma versão prática do Simplex pode ser feita com tabelas (*tableau simplex*).

No caso de não haver apenas restrições \leq , é necessário criar *variáveis artificiais*, bem como um novo problema de otimização que busca *minimizar* o valor delas (a zero!). Nesse PPL estendido, o peso inicial é 0 para as variáveis do PPL original, e 1 para as artificiais. Quando a otimalidade é atingida nesse modelo (e as variáveis artificiais saem da base), podemos cortar as variáveis artificiais, e retornar ao modelo original (fase 2).

Os slides do prof. Marcone detalham o passo-a-passo dessa abordagem: Slides SIMPLEX (pdf).

Lista de Exercícios

A lista de exercícios está disponibilizada no site.